淘宝网 Taobao.com 淘我喜欢！

打造安全易运维的高性能Web平台

——淘宝网Nginx定制开发实战

朱照远（叔度）
王晓哲（清无）

2011-12-06

大纲

- 背景介绍
- 前端优化
- 安全增强
- 典型业务模块
- 运维增强
- 动态脚本与数据库层

1、背景介绍

淘宝网的面临的技术挑战

- 亚洲最大的电子商务网站，Alexa排名12
- 巨大的商品量
  - 商品总数超过10亿
  - 每天在线的商品数超过5亿
  - 每天更新的商品数超过6000万
- 巨大的访问量
  - 每秒钟几百个G的网络流量
  - 日PV超过几十亿的业务线很多

淘宝网使用Nginx的过程

- 2009年开始使用和探索
- 2010年开始开发大量模块
  - 基础的
  - 业务的
- 2011年开始
  - 修改Nginx的内核
  - Tengine项目并开源

淘宝网应用Nginx的收益

- 业务更加稳定
  - Nginx大连接数目支持非常好
  - Nginx本身的内存占用很少，更不会吃swap
- 业务性能更高
  - QPS比Apache要好
  - 节省机器数目
  - 基于Nginx的模块性能往往是之前业务的数倍

2、前端优化

组合JavaScript和CSS文件

- Yahoo!前端优化第一条原则
  - Minimize HTTP Requests
  - 减少三路握手和HTTP请求的发送次数
- 淘宝CDN combo
  - concat模块
  - 将多个JavaScript、CSS请求合并成一个

淘宝CDN Combo的使用

- 以两个问号（??）激活combo特性
- 多个文件之间用逗号（,）分开
- 用一个?来表示时间戳
  - 突破浏览器缓存
- 例子

http://a.tbcdn.cn/**??**s/kissy/1.1.6/kissy-min.js**,**p/global/1.0/global-min.js**,**p/et/et.js**?**t=201109232011030 1.js

强制gzip压缩

- 来自Google的最佳实践
  - 2009、2010年Velocity大会
- 做强制gzip的原因
  - 代理软件、杀毒软件对Accept-Encoding头的修改或去除
  - 访问淘宝的请求>15%没有带Accept-Encoding头

强制gzip的基本原理

- 如果请求中没有Accept-Encoding头或不支持gzip且没有GZ的cookie设置
- 判断浏览器（User-Agent）是否支持gzip
- 发送的内容中插入JavaScript脚本
- 脚本请求一个永远都gzip的URL
- 如果gzip的内容被执行了，说明支持gzip
- 设置GZ对应的cookie值，注明支持gzip

3、安全增强

单机安全方案

- 连接数限制
  - 使用limit_conn模块
- 访问频率限制
  - 加强版的limit_req模块
    - 白名单支持
    - 指定跳转页面支持
    - 同一个location下多limit_req支持

系统过载保护

- 判断依据
  - 系统的loadavg
  - 内存使用（swap的比率）
  - QPS
- sysgurad模块

```
sysguard on;
sysguard_load load=4 action=/high_load.html;
sysguard_mem swapratio=10% action=/mem_high.html
```

过载保护的等待页面

- 过载处理方式
  - 直接弹回（用户不友好，而且没有保护作用）
  - 返回等待页面（用户友好，有保护）
- 等待页面的处理
  - 将用户原来的请求内容返给用户（脚本）
  - 定时器倒计时
  - 时间到了自动发起新的请求

分布式防攻击系统

- 应对的问题
  - 小型的DDoS攻击
  - 恶意的爬虫
- 为什么单机版还不够
  - 单机版无法知道全局
- 淘宝TMD（Taobao Missile Defense）系统
  - Nginx作为防攻击系统的终端
  - TMD Server做策略分析
  - TMD Console执行汇总和控制台

TMD防攻击系统架构

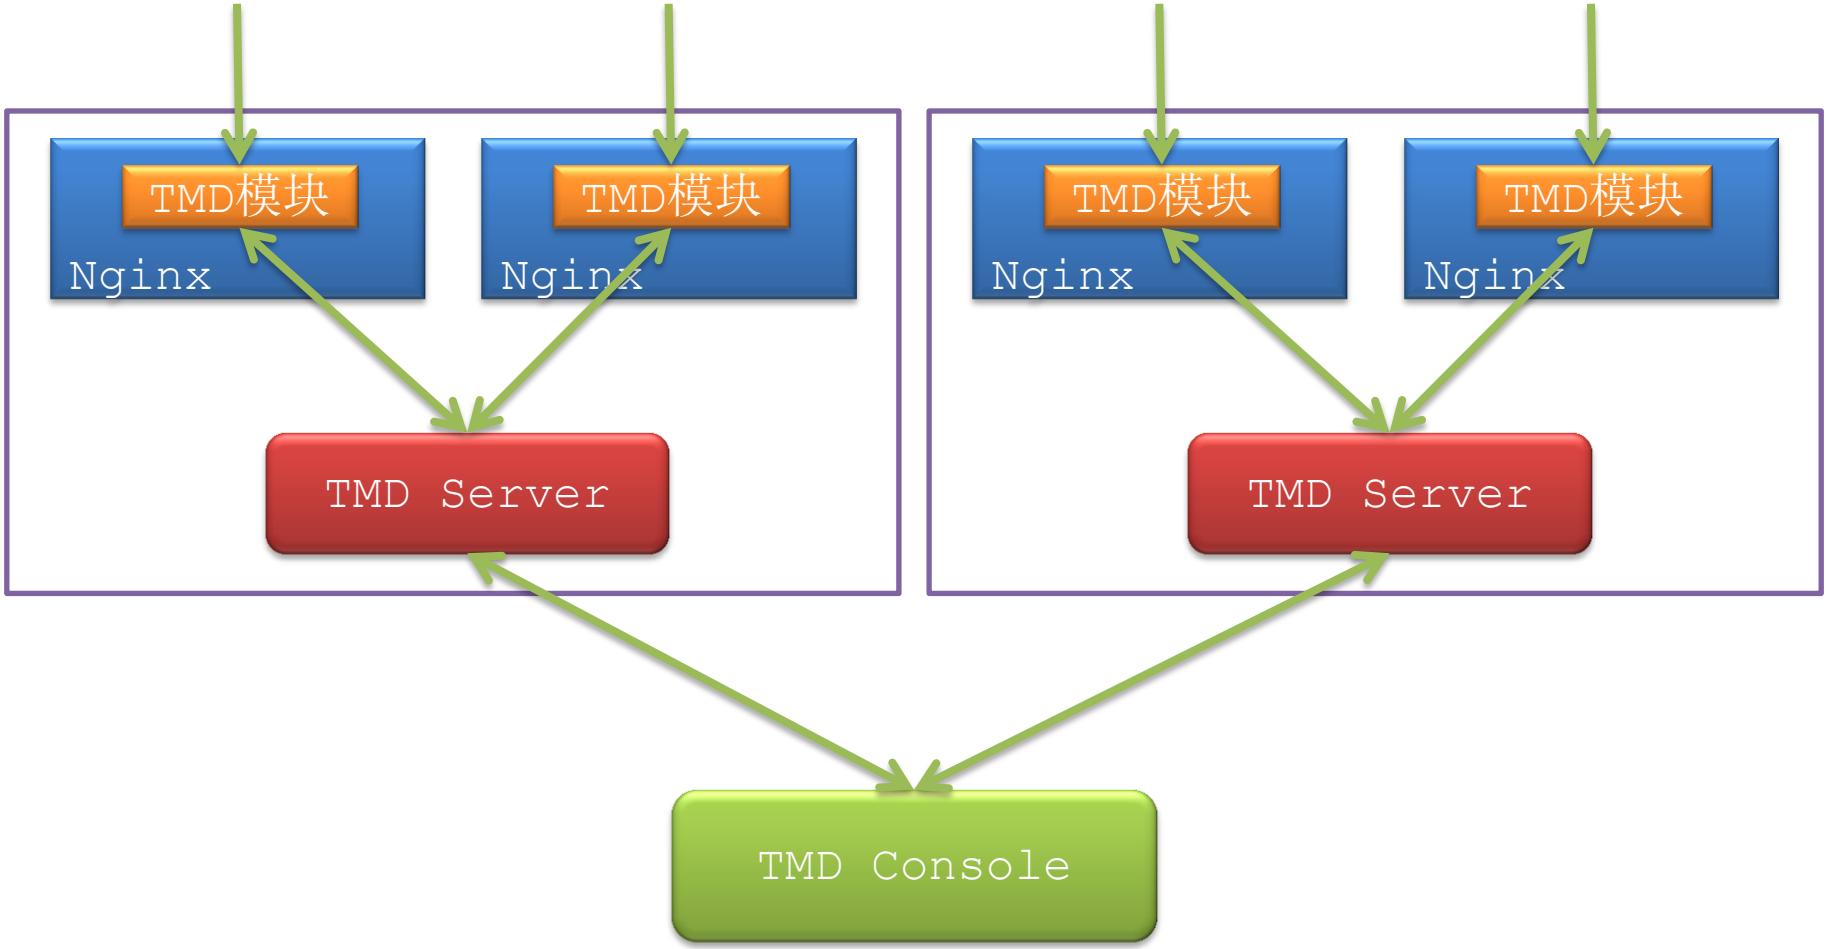

4、典型业务模块

Comet服务器

- Nginx本身的极限测试
  - 单机支持200万连接以上
- 淘宝消息推送系统
  - 部署容量60万连接/台
  - 实际跑到30万连接/台

Comet服务器架构

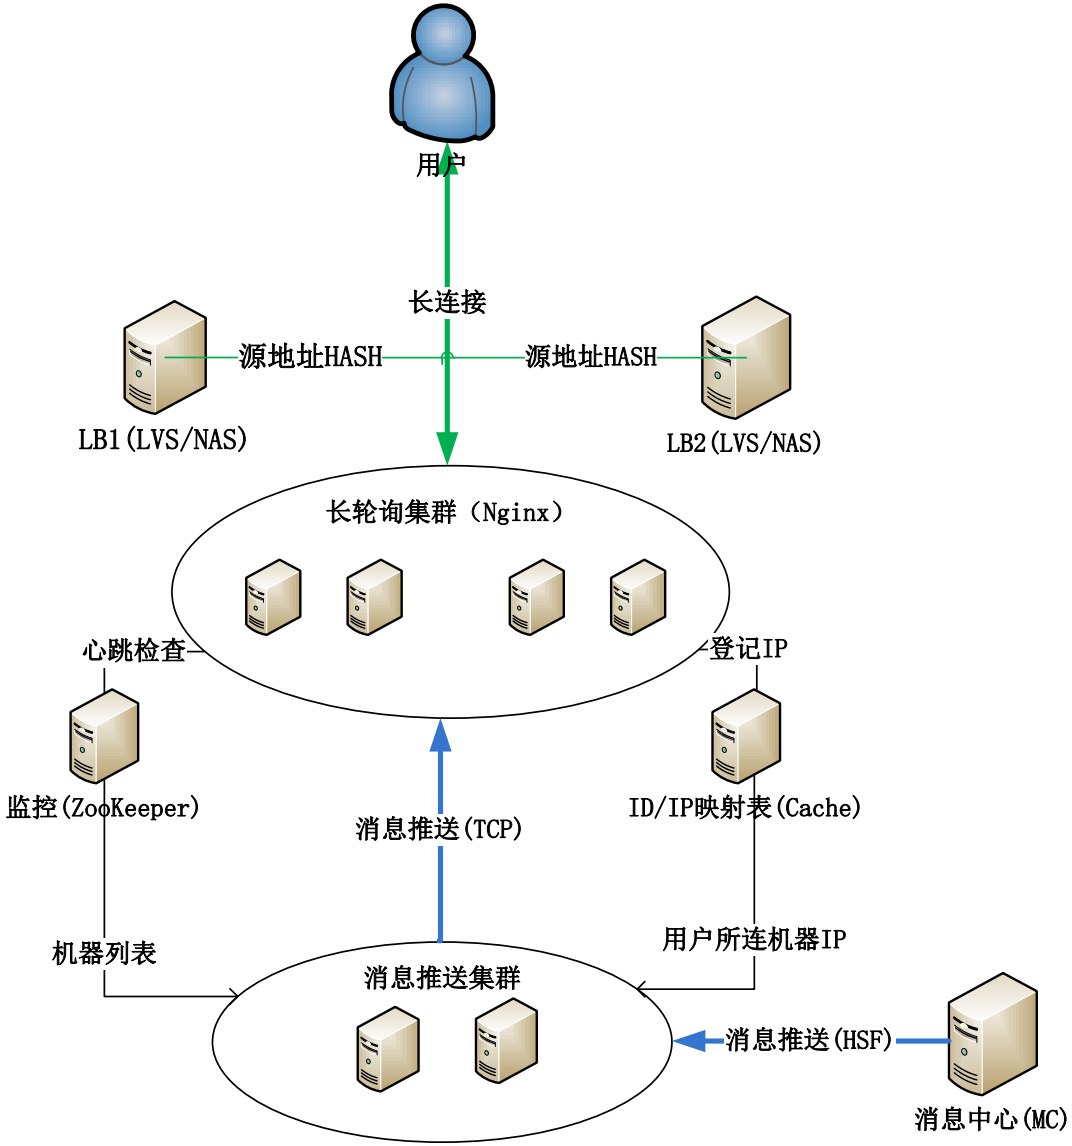

灰度发布

- 逐渐放量
- 方便的管理接口

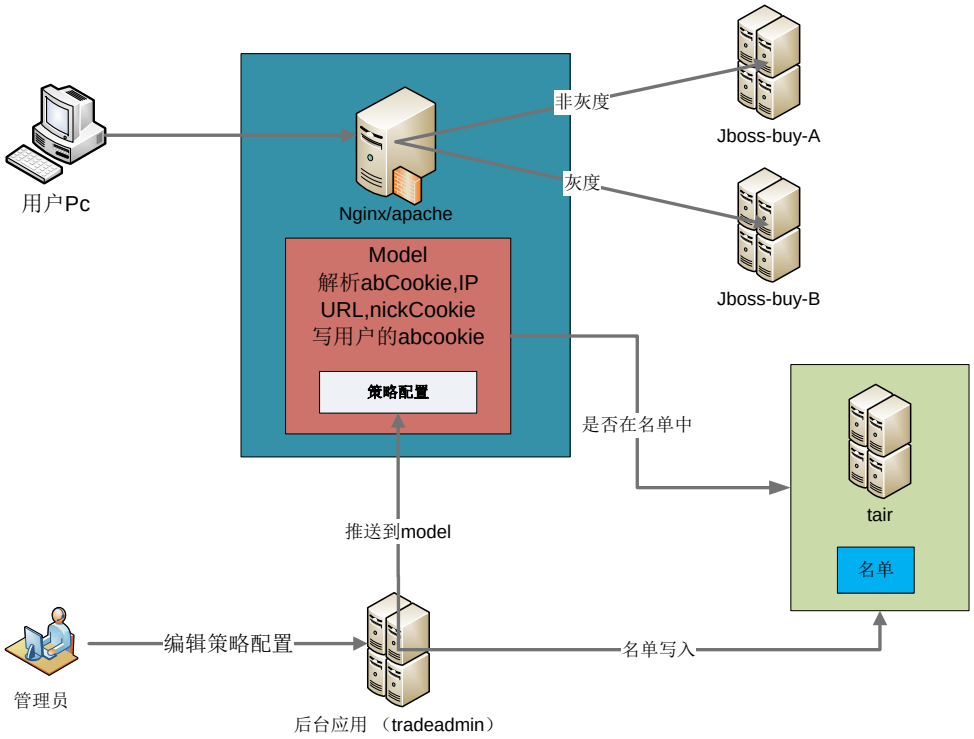

淘宝开源分布式文件系统方案

- TFS模块
  - 非upstream机制
  - RESTful接口
  - 简化了分布式存储方案的使用难度

淘宝开源分布式K/V存储方案

- Tair模块
  - 非upstream机制
  - RESTful接口
- 特点
  - 性能很高
  - 灵活
  - 返回JSON格式给客户端

5、运维增强

多种日志方式

- 本地和远程syslog支持

```
access_log      syslog:user:info:127.0.0.1:514 combined;
```

- 管道支持

```
access_log      pipe:/path/to/cronolog combined;
```

- 抽样支持
  - 减少写日志的数量，避免磁盘写爆

```
access_log      /path/to/file combined ratio=0.01;
```

Server头的伪装

- 伪装

```
server_tag        Apache/2.2.21;
```

```
$ curl -I http://localhost
HTTP/1.1 200 OK
Server: Apache/2.2.21
Date: Sun, 04 Dec 2011 18:36:53 GMT
Content-Type: text/html
Content-Length: 205
Last-Modified: Tue, 01 Nov 2011 05:18:57 GMT
Connection: keep-alive
```

Server头的隐藏

- 隐藏

```
server_tag        off;
```

```
$ curl -I http://localhost
HTTP/1.1 200 OK
Date: Sun, 04 Dec 2011 18:41:16 GMT
Content-Type: text/html
Content-Length: 205
Last-Modified: Tue, 01 Nov 2011 05:18:57 GMT
Connection: keep-alive
```

主机信息调试

- Tengine的footer模块

```
footer $host_comment;
```

- 输出效果

```
$ curl http://localhost
<html>
<head>
<title>Welcome to nginx!</title>
</head>
<body bgcolor="white" text="black">
<center><h1>Welcome to nginx!</h1></center>
</body>
</html>
<!-- shudu-desktop Sat, 03 Dec 2011 09:27:47 GMT -->
```

Tengine错误信息提示

- 便于定位用户反馈的4xx和5xx错误

```
server_info       on;
server_admin      shudu@taobao.com;
```

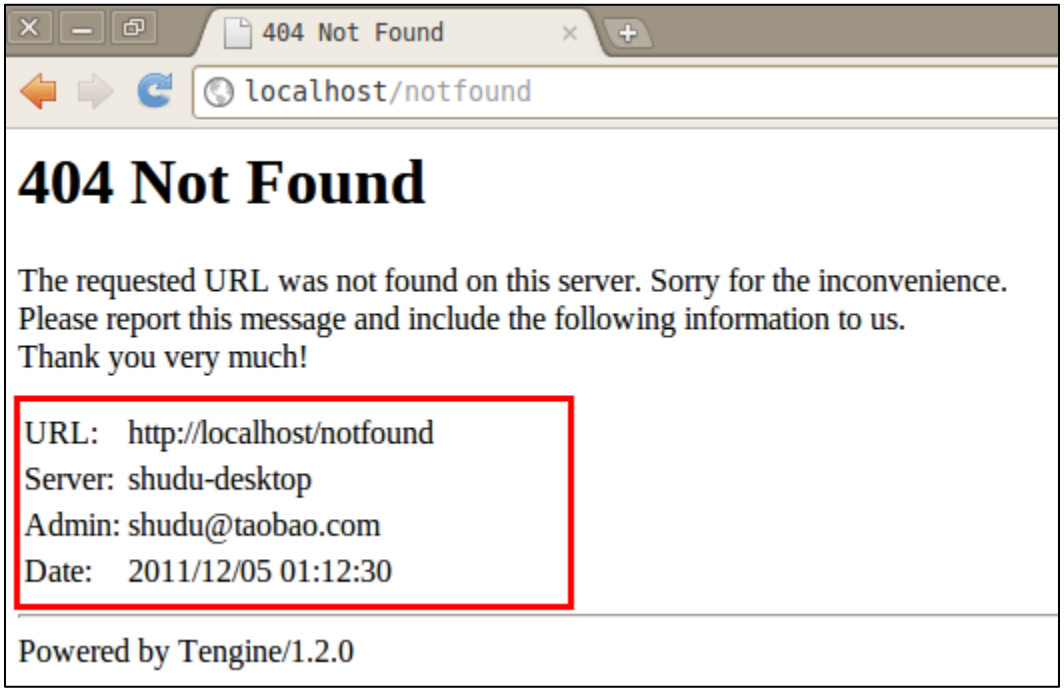

worker进程和CPU亲缘性

- 好处
  - 利用多核
  - 防止CPU的cache失效
- 问题
  - 不同的硬件，CPU核数可能不同
  - 绑定多核的CPU亲缘性比较繁琐

Tengine对于进程设置的简化

- 使用对比

```
# standard nginx
worker_process          8;
worker_cpu_affinity     00000001 00000010 00000100 00001000
                        00010000 00100000 01000000 10000000
```

```
# tengine
#worker_process         auto;
#worker_cpu_affinity    auto;
```

Nginx命令行参数的增加

- 列出已经编译的模块
  - nginx -m
- 列出支持的指令
  - nginx -l
- 输出配置文件的全部内容
  - nginx -d
  - 支持include的内容

Nginx监控增强

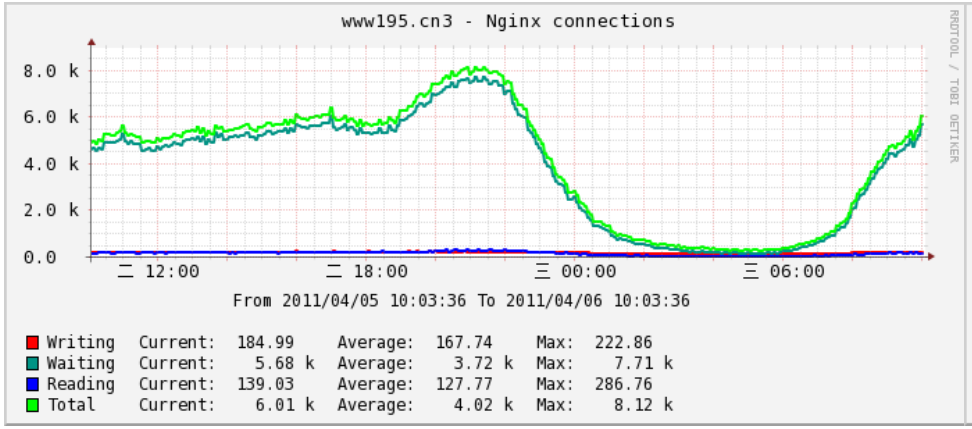

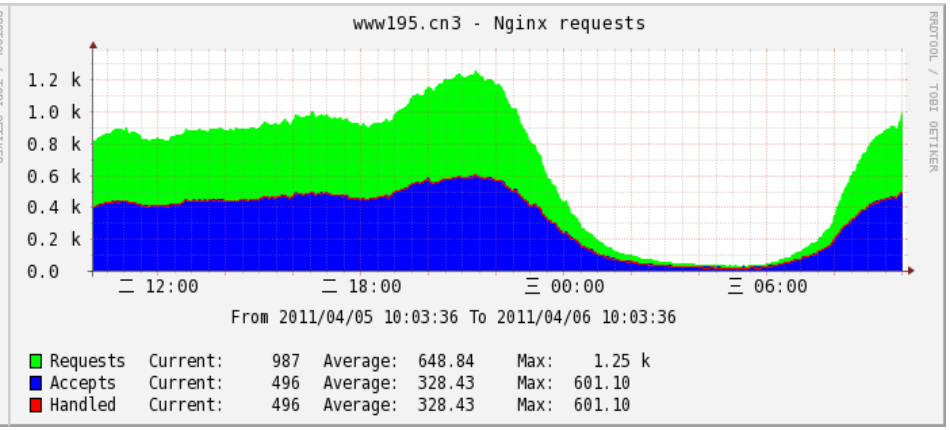

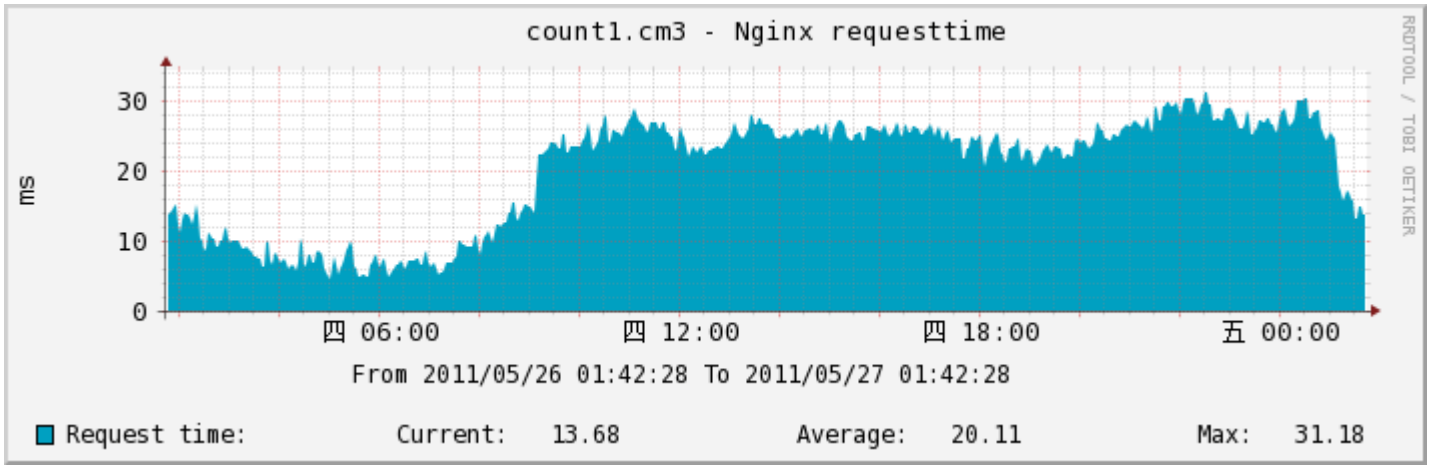

使用淘宝开源监控工具Tsar

- tsar --nginx

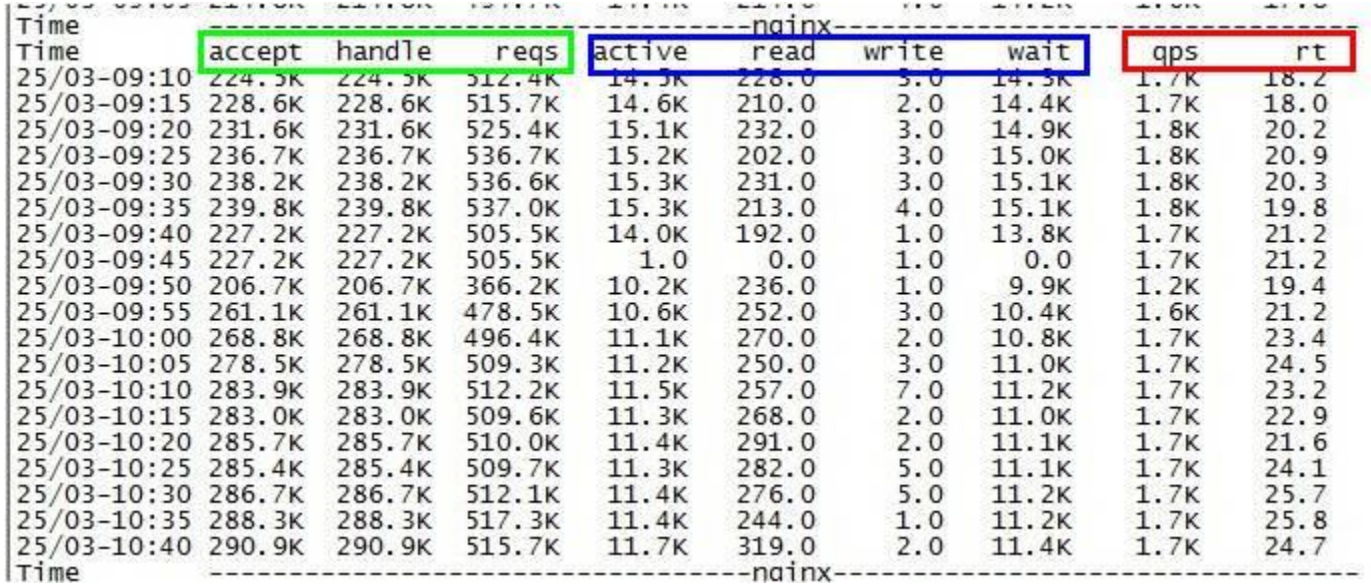

Time	accept	handle	reqs	active	read	write	wait	qps	rt
				nginx					
25/03-09:10	224.5K	224.5K	512.4K	14.5K	228.0	3.0	14.5K	1.7K	18.2
25/03-09:15	228.6K	228.6K	515.7K	14.6K	210.0	2.0	14.4K	1.7K	18.0
25/03-09:20	231.6K	231.6K	525.4K	15.1K	232.0	3.0	14.9K	1.8K	20.2
25/03-09:25	236.7K	236.7K	536.7K	15.2K	202.0	3.0	15.0K	1.8K	20.9
25/03-09:30	238.2K	238.2K	536.6K	15.3K	231.0	3.0	15.1K	1.8K	20.3
25/03-09:35	239.8K	239.8K	537.0K	15.3K	213.0	4.0	15.1K	1.8K	19.8
25/03-09:40	227.2K	227.2K	505.5K	14.0K	192.0	1.0	13.8K	1.7K	21.2
25/03-09:45	227.2K	227.2K	505.5K	1.0	0.0	1.0	0.0	1.7K	21.2
25/03-09:50	206.7K	206.7K	366.2K	10.2K	236.0	1.0	9.9K	1.2K	19.4
25/03-09:55	261.1K	261.1K	478.5K	10.6K	252.0	3.0	10.4K	1.6K	21.2
25/03-10:00	268.8K	268.8K	496.4K	11.1K	270.0	2.0	10.8K	1.7K	23.4
25/03-10:05	278.5K	278.5K	509.3K	11.2K	250.0	3.0	11.0K	1.7K	24.5
25/03-10:10	283.9K	283.9K	512.2K	11.5K	257.0	7.0	11.2K	1.7K	23.2
25/03-10:15	283.0K	283.0K	509.6K	11.3K	268.0	2.0	11.0K	1.7K	22.9
25/03-10:20	285.7K	285.7K	510.0K	11.4K	291.0	2.0	11.1K	1.7K	21.6
25/03-10:25	285.4K	285.4K	509.7K	11.3K	282.0	5.0	11.1K	1.7K	24.1
25/03-10:30	286.7K	286.7K	512.1K	11.4K	276.0	5.0	11.2K	1.7K	25.7
25/03-10:35	288.3K	288.3K	517.3K	11.4K	244.0	1.0	11.2K	1.7K	25.8
25/03-10:40	290.9K	290.9K	515.7K	11.7K	319.0	2.0	11.4K	1.7K	24.7
Time				nginx					

6、动态脚本与数据库层

背景

- 淘宝量子统计业务快速发展
  - 原架构无法满足业务需要
- 量子统计页面和数据特征
  - 页面主体框架基本不变
  - 查询复杂速度慢
  - 结果集数据量大
  - 重复查询少

思考

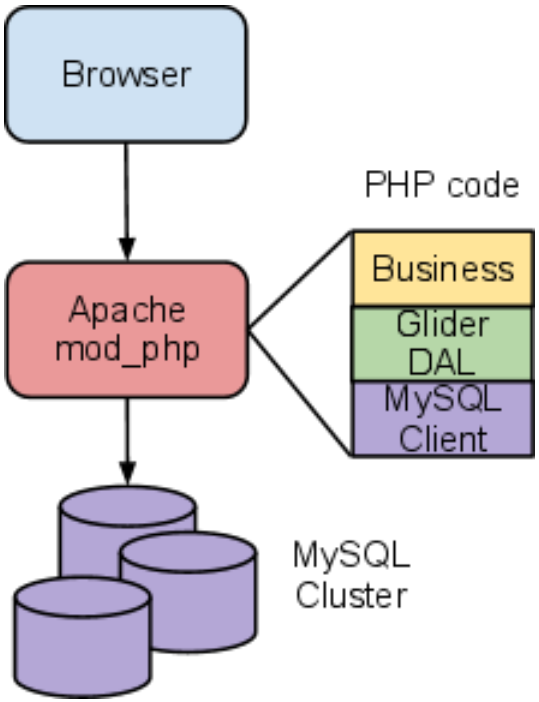

- 优点
  - 易于理解，开发上手快
- 缺点
  - 页面主体内容重复浪费带宽
  - 单机并发服务能力极为有限
  - 存在慢连接攻击风险
  - PHP代码处理大数据时速度低下

方案

- 更改服务模型
- 静态资源CDN化
- 服务侧页面组装过程移至浏览器侧

演进

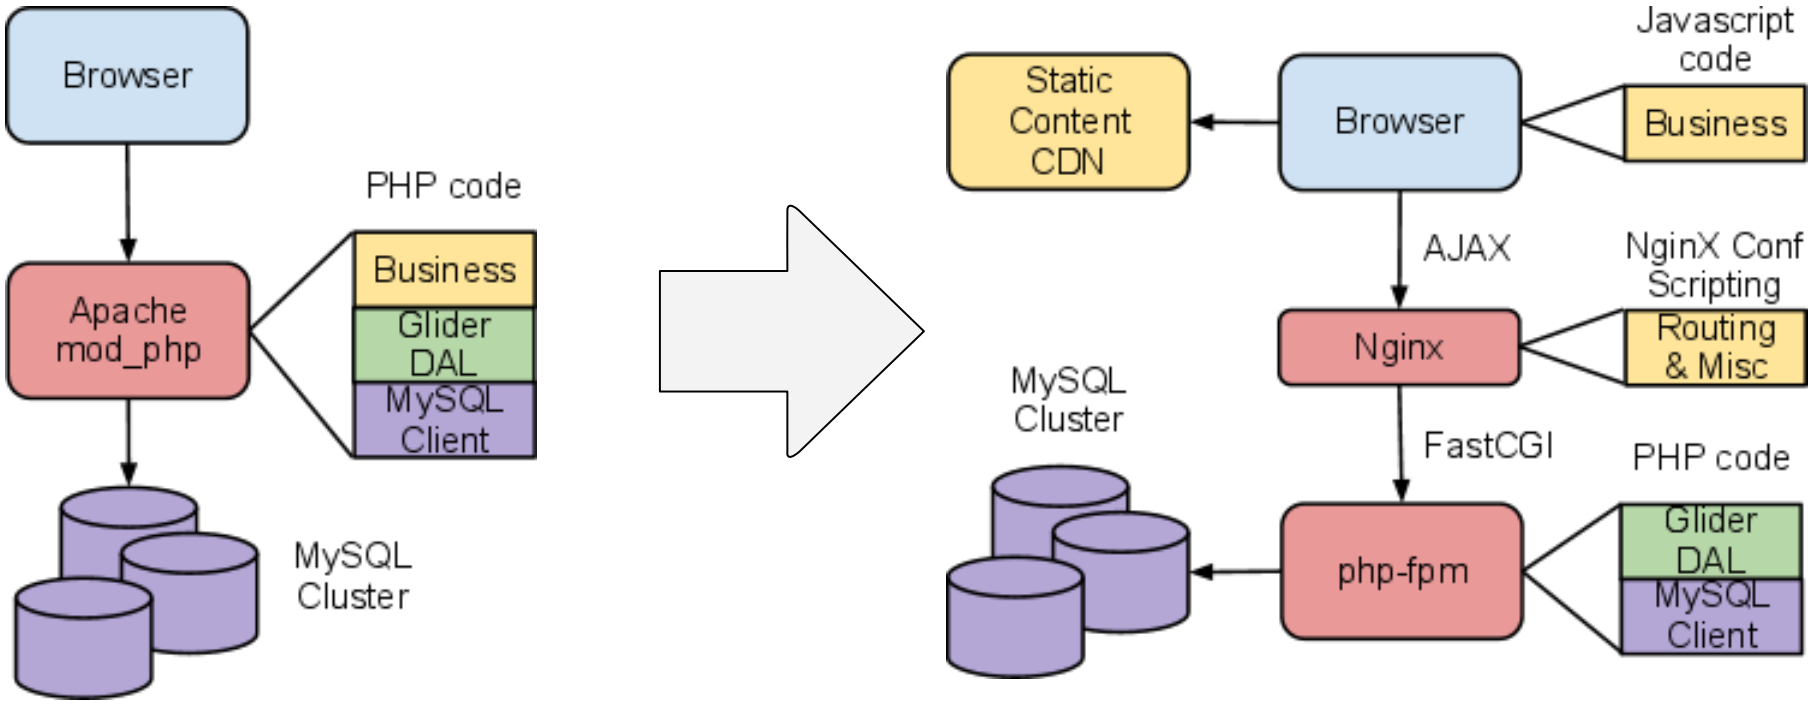

思考

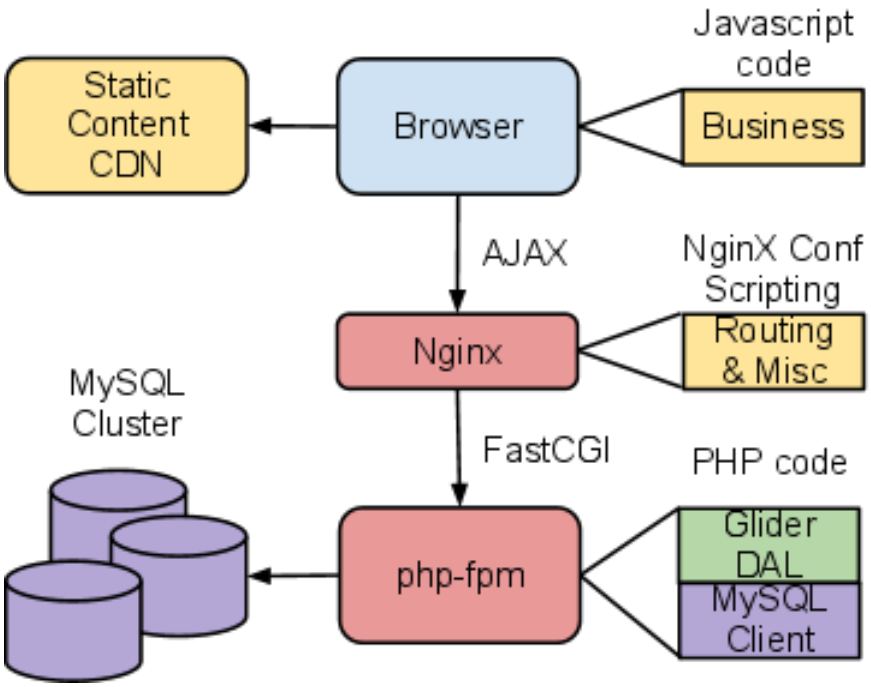

- 优点
  - 避免带宽浪费
  - 减少服务端计算量
  - 提升并发服务能力，可抵御慢连接攻击
- 缺点
  - 开发效率受限
  - PHP+FastCGI限制整体吞吐量提升

方案

- 要在Nginx中高效访问MySQL数据库
  - ngx_drizzle诞生！
- 要有适用Nginx I/O模型的高速脚本引擎
  - ngx_lua诞生！

ngx_drizzle

- 实现Nginx中同步非阻塞方式访问MySQL
- 具备长连接、进程级可控大小连接池和负载均衡功能
- 返回数据可通过ngx_rds_json/csv等模块转换为JSON/CSV格式

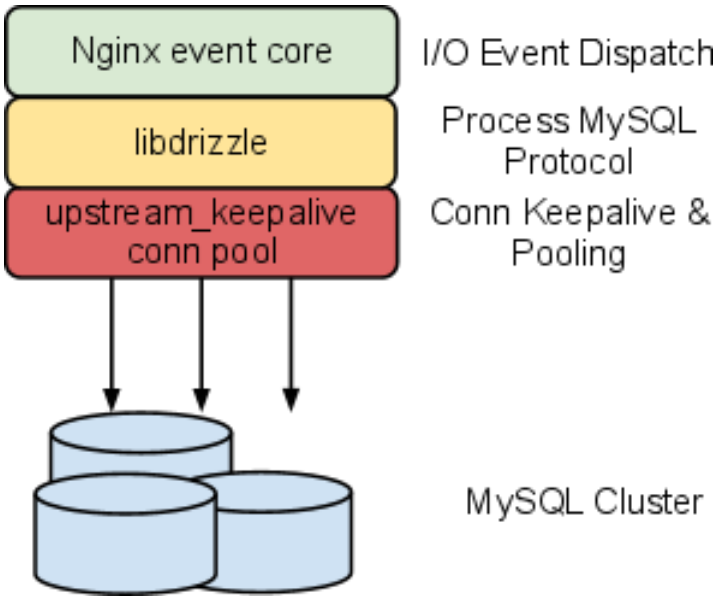

ngx_drizzle示例

```
http {
    ...
    upstream dbgroup {
        drizzle_server host1:3306 dbname=test password=some_pass user=alice protocol=mysql;
        drizzle_server host2:3306 dbname=test2 password=some_pass user=bob protocol=mysql;
    }
    ...
    server {
        location /mysql {
            set $sql "select * from cats";
            drizzle_query $sql;
            drizzle_pass dbgroup;
            rds_json on;
        }
    }
}
```

Nginx C模块构建业务逻辑的问题

- 开发效率低
- 部署灵活性差

但是……

- 人人都喜欢脚本语言！
- ngx_lua用Lua脚本构建业务逻辑！

Why Lua?

- 内存开销小
- 运行速度快
- VM可中断/重入

chart reset

compare 2	|-	|---	25%	median	75%	---|	-|
C **GNU gcc**	1.00	1.00	1.04	**1.09**	1.35	1.83	3.80
C++ **GNU g++**	1.00	1.00	1.00	**1.11**	1.24	1.55	1.55
ATS	1.00	1.00	1.00	**1.26**	1.57	2.42	7.19
Java **6 steady state**	1.00	1.00	1.15	**1.57**	1.96	2.06	2.06
Lua **LuaJIT**	1.03	1.03	1.83	**1.98**	8.73	10.51	10.51
Scala	1.14	1.14	1.19	**2.00**	2.39	4.19	6.67
Fortran **Intel**	1.00	1.00	1.56	**2.18**	6.38	10.54	10.54
Java **6 -server**	1.10	1.10	1.36	**2.18**	3.63	6.80	6.80
Ada 2005 **GNAT**	1.00	1.00	1.40	**2.22**	3.66	7.05	7.44
Pascal **Free Pascal**	1.36	1.36	1.89	**2.35**	3.50	4.77	4.77
Haskell **GHC**	1.14	1.14	1.92	**2.38**	3.97	7.04	8.08
Clean	1.29	1.29	1.93	**2.67**	5.76	9.58	9.58
C# **Mono**	1.69	1.69	1.97	**2.84**	5.16	9.95	18.38
OCaml	1.49	1.49	2.52	**3.04**	3.87	4.62	4.62
F# **Mono**	1.93	1.93	1.99	**3.22**	3.95	6.88	10.54
Lisp **SBCL**	1.00	1.00	2.47	**3.29**	7.11	12.44	12.44
Racket	1.45	1.45	2.84	**4.38**	8.01	15.77	19.20
Go **6g 8g**	2.65	2.65	3.70	**4.66**	12.40	25.43	125.45
JavaScript **V8**	1.00	1.00	4.26	**7.19**	20.52	44.89	102.86
Erlang **HiPE**	1.64	1.64	5.60	**7.70**	20.91	34.93	34.93
Clojure	1.55	1.55	4.68	**11.47**	15.59	29.58	29.58
JavaScript **TraceMonkey**	1.73	1.73	4.39	**12.66**	28.53	64.75	898.17
Smalltalk **VisualWorks**	11.27	11.27	12.34	**15.73**	26.42	47.54	71.80
Java **6 -Xint**	7.37	7.37	14.91	**23.85**	32.36	58.53	72.81
Lua	1.03	1.03	21.82	**31.53**	41.70	51.54	51.54
Python **PyPy**	13.90	13.90	26.29	**32.29**	47.29	78.80	122.93
Ruby **JRuby**	16.50	16.50	23.95	**43.08**	153.45	225.45	225.45
Python **CPython**	2.28	2.28	5.74	**47.96**	93.11	106.47	106.47
Python 3	2.23	2.23	7.10	**50.09**	128.75	157.73	157.73
Python **IronPython**	20.41	20.41	33.78	**58.41**	86.05	164.46	190.75
Mozart/Oz	7.57	7.57	32.47	**63.37**	85.64	165.40	197.18
Ruby **1.9**	7.64	7.64	15.33	**63.66**	106.91	244.27	265.59
Perl	2.39	2.39	9.48	**73.69**	154.39	218.38	218.38
PHP	6.90	6.90	48.32	**104.15**	149.90	233.84	233.84
Ruby **MRI**	15.28	15.28	24.72	**158.27**	481.13	837.28	837.28

chart reset

原理

- ngx_lua实现Proactor模型
  - 业务逻辑以自然逻辑书写
  - 自动获得高并发能力
  - 不会因I/O阻塞等待而浪费CPU资源

原理

- 每Nginx工作进程使用一个Lua VM，工作进程内所有协程共享VM
- 将Nginx I/O原语封装后注入Lua VM，允许Lua代码直接访问
- 每个外部请求都由一个Lua协程处理，协程之间数据隔离
- Lua代码调用I/O操作接口时，若该操作无法立刻完成，则打断相关协程的运行并保护上下文数据
- I/O操作完成时还原相关协程上下文数据并继续运行

```
resolver ip.to.dns.server;

location /http_client {
    internal;
    proxy_pass $arg_url;
}

location /web_iconv {
    content_by_lua '
        local from, to, url = ngx.var.arg_f, ngx.var.arg_t, ngx.var.arg_u
        local capture = ngx.location.capture
        local iconv = require "iconv"
        local cd = iconv.new(to or "utf8", from or "gbk")
        local res = capture("/http_client?url=" .. url)
        if res.status == 200 then
            local ostr, err = cd:iconv(res.body)
            ngx.print(ostr)
        else
            ngx.say("error occured: rc=" .. res.status)
        end
    ';
}
```

演进

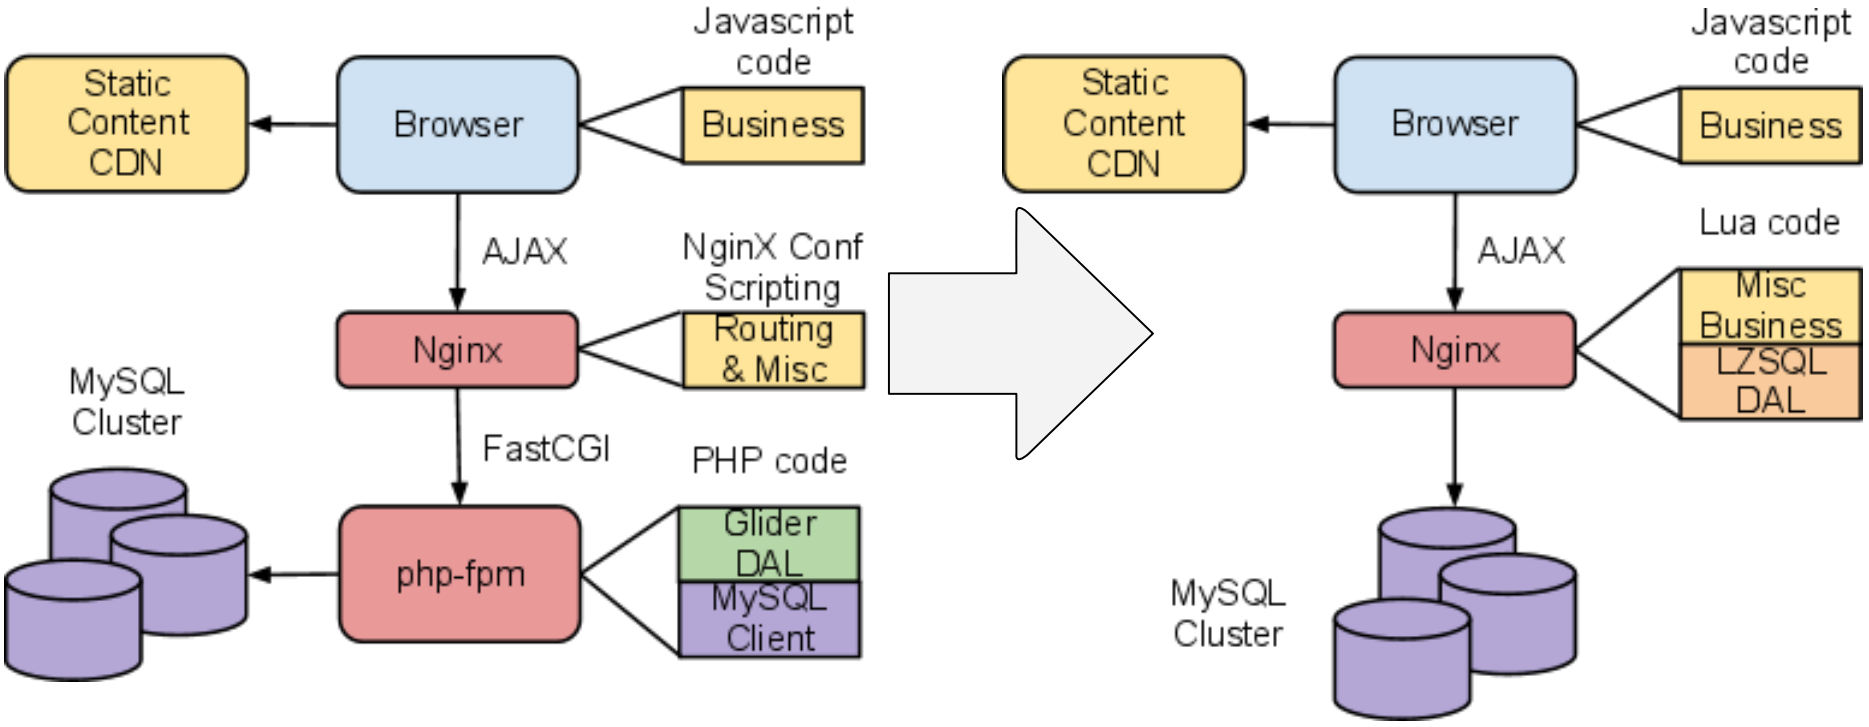

效果

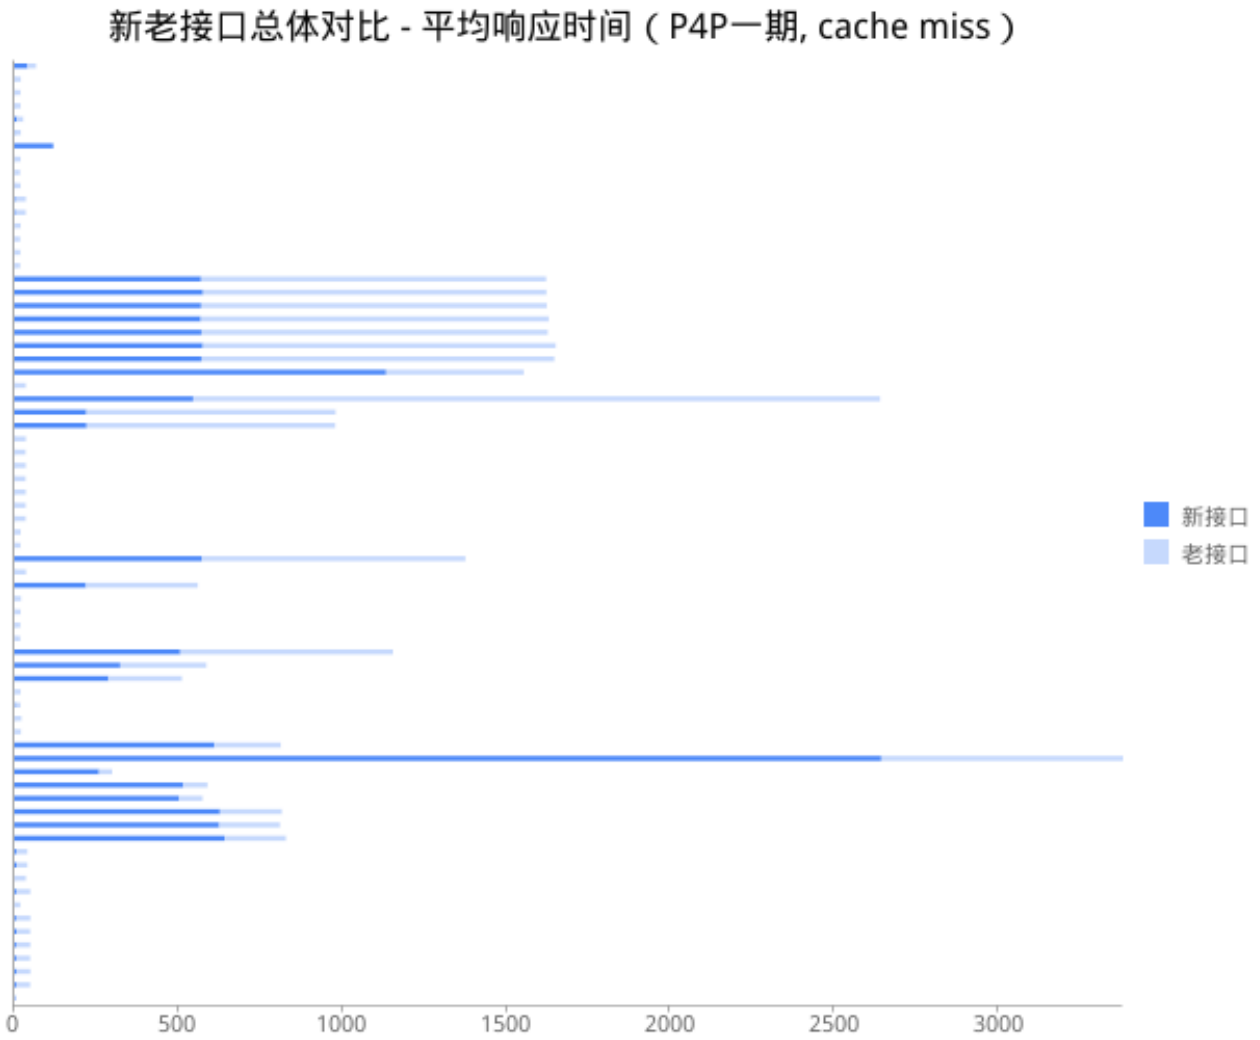

思考

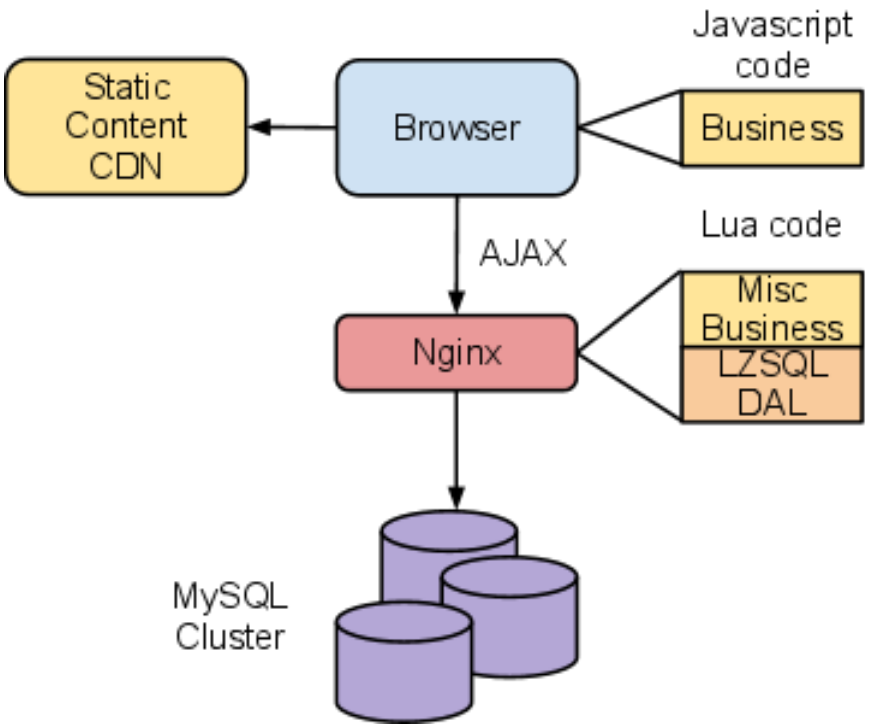

- 优点
  - 服务侧开发语言同质化，开发效率明显提升
  - 大数据请求处理速度大幅度提高
- 完美的方案？

思考

- 协作式调度模型的问题
- Lua代码死循环
- I/O操作受限于Nginx模型
- 调试功能

参考

- 本演示稿中涉及的大部分技术已经开源：
  - http://tengine.taobao.org
  - https://github.com/chaoslawful/lua-nginx-module
  - https://github.com/chaoslawful/drizzle-nginx-module
  - https://github.com/agentzh/ngx_openresty

欢迎加入我们！

shudu@taobao.com

新浪微博 @淘叔度

qingwu@taobao.com

新浪微博 @chaoslawful